

Projektarbeit

Klassifikation und Analyse der Weinqualität mit KNIME und Power BI

Autor: Amin Zamen Ali

Kurzbeschreibung

In dieser Projektarbeit werden Rot- und Weißweindaten analysiert. Ziel ist es, die Weinqualität anhand chemischer Merkmale in die Klassen low, medium und high einzuordnen. Die Datenaufbereitung, Analyse und Modellierung wurden in KNIME umgesetzt. Die wichtigsten Ergebnisse wurden zusätzlich in Power BI als Dashboard visualisiert.

Inhaltsverzeichnis

1. Ausgangssituation und Zielsetzung
 - 1.1 Ist-Analyse
 - 1.2 Projektziele und Backlog
 - 1.3 Hypothesen
 - 1.4 Definition of Done
2. Datengrundlage
3. Datenaufbereitung und Workflow-Vorgehen
4. Explorative Datenanalyse
5. Modellierung
6. Modellbewertung und Modellvergleich
7. Interpretation der Ergebnisse und Merkmalsbedeutung
8. Power-BI-Dashboard
9. Grenzen des Modells
10. Fazit und Ausblick

1. Ausgangssituation und Zielsetzung

Im Rahmen der Projektarbeit wird ein Datensatz zur Weinqualität analysiert. Der Datensatz enthält chemische Merkmale von Rot- und Weißwein sowie eine numerische Qualitätsbewertung. Ziel des Projekts ist es, auf Basis dieser Merkmale ein Klassifikationsmodell zu entwickeln, das Weine in die Qualitätsklassen low, medium und high einordnet.

Dafür wird ein vollständiger Datenanalyseprozess umgesetzt. Dieser umfasst Import und Zusammenführung der Daten, Prüfung und Bereinigung, explorative Datenanalyse, Modellvorbereitung, Training und Bewertung verschiedener Modelle sowie die Visualisierung der Ergebnisse in Power BI.

Als Modelle werden ein Decision Tree und ein Random Forest eingesetzt. Die Modellleistung wird anhand von Accuracy, Makro-F1 und Cohen's Kappa bewertet. Zusätzlich wird eine 5-fache geschichtete Cross Validation durchgeführt, um die Stabilität des Random-Forest-Modells zu überprüfen.

Das Ziel ist nicht nur die Erstellung eines funktionsfähigen Modells, sondern auch eine nachvollziehbare Interpretation der Ergebnisse. Dazu werden wichtige Einflussmerkmale analysiert und die Ergebnisse in Bericht, Excel-Export, Power-BI-Dashboard und Präsentation aufbereitet.

1.1 Ist-Analyse

Zu Beginn des Projekts lagen zwei getrennte Ausgangsdatsätze vor: ein Datensatz für Rotwein und ein Datensatz für Weißwein. Beide Dateien enthielten chemische Merkmale der Weine sowie eine numerische Qualitätsbewertung. Eine gemeinsame Datengrundlage war zunächst noch nicht vorhanden.

Die Daten mussten daher zuerst importiert, geprüft und zusammengeführt werden. Zusätzlich war eine Kennzeichnung der Weinart erforderlich, damit Rot- und Weißwein im gemeinsamen Datensatz weiterhin unterschieden werden konnten. Vor der weiteren Analyse mussten mögliche Datenqualitätsprobleme betrachtet und exakte Duplikate entfernt werden.

Die ursprüngliche Qualitätsbewertung lag als numerischer Wert vor. Für die geplante Klassifikation war deshalb eine Umwandlung in Qualitätsklassen notwendig. Aus der numerischen Bewertung wurde die Zielvariable `quality_category` mit den Klassen low, medium und high gebildet.

Zu Projektbeginn existierten noch keine explorativen Auswertungen, kein trainiertes Modell, kein Modellvergleich, kein Dashboard und keine exportierten Ergebnisdateien. Der Ausgangszustand erforderte daher einen vollständigen Datenanalyseprozess von der Datenaufbereitung bis zur Visualisierung.

1.2 Projektziele und Backlog

Für die Umsetzung wurden zentrale Arbeitspakete als einfaches Backlog festgehalten. Dadurch ist nachvollziehbar, welche fachlichen und technischen Schritte bis zum Projektabschluss erfüllt werden mussten.

Ziel / Arbeitspaket	Nutzen für das Projekt	Priorität	Status
Rot- und Weißweindaten importieren	Ausgangsdaten in KNIME verfügbar machen	hoch	erfüllt
Daten zusammenführen und Weinart kennzeichnen	gemeinsame Analyse von Rot- und Weißwein ermöglichen	hoch	erfüllt
Datenqualität prüfen und Duplikate entfernen	saubere und belastbare Analysegrundlage schaffen	hoch	erfüllt
Zielvariable low/medium/high bilden	Klassifikationsproblem definieren	hoch	erfüllt
Explorative Datenanalyse durchführen	Muster und Zusammenhänge im Datensatz erkennen	hoch	erfüllt
Decision Tree und Random	verschiedene Modellansätze vergleichen	hoch	erfüllt

Forest trainieren			
Modellbewertung durchführen	Modellleistung über Accuracy, Makro-F1 und Kappa beurteilen	hoch	erfüllt
Ergebnisse exportieren	Grundlage für Bericht und Dashboard bereitstellen	hoch	erfüllt
Power-BI-Dashboard erstellen	Ergebnisse interaktiv und verständlich visualisieren	hoch	erfüllt

Tabelle A: Backlog und Projektziele

1.3 Hypothesen

Vor und während der Analyse wurden fachliche Hypothesen formuliert und mit den erstellten Auswertungen überprüft. Die Hypothesen halfen dabei, die explorative Analyse und die Interpretation zielgerichtet aufzubauen.

Hypothese	Prüfung im Projekt	Ergebnis
H1: Weine mit höherem Alkoholgehalt weisen tendenziell eine bessere Qualität auf.	Boxplot und Korrelationsanalyse	bestätigt
H2: Eine höhere flüchtige Säure tritt eher bei niedrigeren Qualitätsklassen auf.	Boxplot nach Qualitätsklasse	teilweise bestätigt
H3: Rot- und Weißwein unterscheiden sich in einzelnen chemischen Merkmalen.	Boxplots nach Weinart	bestätigt
H4: Der Random Forest erzielt bessere Ergebnisse als der Decision Tree.	Modellvergleich mit Accuracy, Makro-F1 und Kappa	bestätigt
H5: Die Cross Validation bestätigt eine relativ stabile Modellleistung.	Vergleich Testbewertung und 5-fache Cross Validation	bestätigt

Tabelle B: Fachliche Hypothesen und Prüfung

1.4 Definition of Done

Für den Abschluss des Projekts wurde festgelegt, welche Ergebnisse vorhanden sein müssen. Die folgende Übersicht zeigt die wichtigsten Kriterien und ihren Status.

Bereich	Definition of Done	Status
Datenimport	Rot- und Weißweindaten sind importiert und zusammengeführt.	erfüllt
Datenbereinigung	Datenqualität wurde geprüft und exakte Duplikate wurden entfernt.	erfüllt
Zielvariable	Die Qualitätsklassen low, medium und high wurden gebildet.	erfüllt
EDA	Zentrale Visualisierungen und Korrelationsanalyse wurden erstellt.	erfüllt
Modellierung	Decision Tree und Random Forest wurden trainiert.	erfüllt
Modellbewertung	Accuracy, Makro-F1 und Cohen's Kappa wurden verglichen.	erfüllt
Export	Modellvergleich, Merkmalsbedeutung und wine_clean.csv wurden exportiert.	erfüllt
Dashboard	Power-BI-Dashboard und Dashboard-Funktionsbeschreibung wurden erstellt.	erfüllt
Dokumentation	Projektbericht, Workflow-Beschreibung, README und Präsentation wurden erstellt.	erfüllt

Tabelle C: Definition of Done

2. Datengrundlage

Für die Projektarbeit wurden zwei Datensätze verwendet: ein Datensatz für Rotwein und ein Datensatz für Weißwein. Beide Datensätze enthalten chemische Messwerte der Weine sowie eine numerische Qualitätsbewertung.

Zu den chemischen Merkmalen gehören unter anderem Alkoholgehalt, Dichte, flüchtige Säure, Zitronensäure, Restzucker, Chloride, Schwefeldioxid, pH-Wert und Sulfate. Diese Merkmale bilden die Grundlage für die spätere Analyse und Modellierung.

Da Rotwein und Weißwein zunächst in getrennten Dateien vorlagen, wurden beide Datensätze separat importiert. Anschließend wurde eine zusätzliche Spalte eingefügt, um die Weinart zu kennzeichnen. Danach wurden beide Datensätze zu einem gemeinsamen Gesamtdatensatz zusammengeführt.

Nach der Bereinigung standen 5.320 Datensätze mit 14 Spalten für die weitere Analyse zur Verfügung. Der bereinigte Datensatz enthält keine fehlenden Werte und keine exakten Duplikate.

Die ursprüngliche Qualitätsbewertung wurde in drei Qualitätsklassen eingeteilt: low, medium und high. Dadurch konnte die Aufgabenstellung als Klassifikationsproblem umgesetzt werden.

Datengrundlage	Beschreibung	Anzahl Datensätze	Hinweis
winequality-red.csv	Rotweindaten mit chemischen Merkmalen und Qualitätsbewertung	1.599	Ausgangsdatei
winequality-white.csv	Weißweindaten mit chemischen Merkmalen und Qualitätsbewertung	4.898	Ausgangsdatei
Zusammengeführter Datensatz	Rot- und Weißweindaten nach Ergänzung der Weinart	6.497	Grundlage vor Bereinigung
Bereinigter Datensatz	Datensatz nach Entfernung exakter Duplikate	5.320	Grundlage für Analyse, Modellierung und Dashboard

Tabelle 1: Überblick über die verwendeten Datensätze

3. Datenaufbereitung und Workflow-Vorgehen

Die Datenaufbereitung wurde in KNIME schrittweise und nachvollziehbar umgesetzt. Zunächst wurden die Datensätze für Rotwein und Weißwein über separate CSV Reader Nodes importiert. Da beide Datensätze die gleiche Grundstruktur besitzen, konnten sie nach der Ergänzung einer zusätzlichen Spalte zur Weinart zusammengeführt werden.

Für jeden Datensatz wurde mit einem Constant Value Column Appender eine neue Spalte eingefügt. Diese kennzeichnet, ob es sich um Rotwein oder Weißwein handelt. Anschließend wurden beide Datensätze mit dem Concatenate Node zu einem gemeinsamen Datensatz verbunden.

Nach der Zusammenführung wurde der Datensatz mit dem Data Explorer geprüft. Dabei wurden Datentypen, Wertebereiche, Verteilungen und mögliche Auffälligkeiten betrachtet. Anschließend wurden mit dem Duplicate Row Filter exakte Duplikate entfernt.

Die ursprüngliche Qualitätsbewertung wurde mit dem Rule Engine Node in die Qualitätsklassen low, medium und high umgewandelt. Der bereinigte Gesamtdatensatz wurde anschließend als wine_clean.csv für Power BI exportiert.

Vor dem Training der Modelle wurde die ursprüngliche numerische Qualitätsvariable quality aus dem Modellinput entfernt. Dies war notwendig, um Data Leakage zu vermeiden. Zusätzlich wurde die Weinart mit dem One to Many Node numerisch kodiert. Danach wurde der Datensatz mit dem Table Partitioner geschichtet in Trainings- und Testdaten aufgeteilt.

Abbildung 1: Gesamtübersicht des aktualisierten KNIME-Workflows




Abbildung 1: Aktualisierte Gesamtübersicht des KNIME-Workflows mit strukturierten Analyseblöcken

4. Explorative Datenanalyse

Nach der Datenaufbereitung wurde eine explorative Datenanalyse durchgeführt, um erste Muster und Zusammenhänge im Datensatz zu erkennen. Ziel war es, die Verteilung der Qualitätsklassen zu prüfen und wichtige Einflussmerkmale für die Weinqualität besser zu verstehen.

Die Verteilung der Zielvariable zeigt, dass die Klasse medium am häufigsten vorkommt. Die Klassenverteilung beträgt: low mit 1.988 Datensätzen, medium mit 2.323 Datensätzen und high mit 1.009 Datensätzen.

Mithilfe von Boxplots wurde untersucht, wie sich Merkmale wie Alkoholgehalt, flüchtige Säure, Restzucker und Schwefeldioxid zwischen den Qualitätsklassen beziehungsweise zwischen Rot- und Weißwein unterscheiden.

Die Analyse zeigte, dass Weine mit höherer Qualität tendenziell einen höheren Alkoholgehalt aufweisen. Gleichzeitig war erkennbar, dass flüchtige Säure bei besseren Qualitätsklassen eher niedriger ausfällt. Außerdem zeigten sich Unterschiede zwischen Rot- und Weißwein, insbesondere bei Restzucker und Schwefeldioxid.

Zusätzlich wurde eine Korrelationsanalyse durchgeführt. Der Alkoholgehalt zeigte den stärksten positiven Zusammenhang mit der ursprünglichen Qualitätsbewertung. Zwischen Dichte und Alkoholgehalt bestand dagegen ein deutlicher negativer Zusammenhang.




Abbildung 2: Verteilung der Qualitätsklassen im bereinigten Datensatz

5. Modellierung

Für die Modellierung wurde die Zielvariable `quality_category` verwendet. Diese enthält die drei Qualitätsklassen low, medium und high. Ziel war es, auf Basis der chemischen Merkmale die passende Qualitätsklasse eines Weins vorherzusagen.

Der Datensatz wurde vor dem Training in Trainings- und Testdaten aufgeteilt. Dabei wurden 80 % der Daten für das Training und 20 % der Daten für den Test verwendet. Die Aufteilung erfolgte geschichtet nach der Zielvariable, damit alle drei Qualitätsklassen in beiden Datenmengen angemessen vertreten sind.

Als erstes Modell wurde ein Decision Tree trainiert. Dieses Modell wurde als einfaches und gut interpretierbares Vergleichsmodell eingesetzt.

Als zweites Modell wurde ein Random Forest trainiert. Der Random Forest besteht aus mehreren Entscheidungsbäumen und kombiniert deren Ergebnisse. Dadurch ist das Modell in der Regel stabiler als ein einzelner Entscheidungsbaum. In diesem Projekt wurde der Random Forest mit 100 Entscheidungsbäumen trainiert.

Nach dem Training wurden beide Modelle auf den Testdaten angewendet. Die vorhergesagten Qualitätsklassen wurden anschließend mit den tatsächlichen Qualitätsklassen verglichen.

Zusätzlich wurde für den Random Forest eine 5-fache geschichtete Cross Validation durchgeführt. Damit wurde geprüft, ob die Modellleistung auch bei mehreren unterschiedlichen Trainings- und Testaufteilungen relativ stabil bleibt.

6. Modellbewertung und Modellvergleich

Die trainierten Modelle wurden mithilfe des Scorer Nodes bewertet. Dabei wurden die vorhergesagten Qualitätsklassen mit den tatsächlichen Qualitätsklassen aus den Testdaten verglichen. Zur Bewertung wurden mehrere Kennzahlen verwendet.

Die Accuracy zeigt den Anteil korrekt klassifizierter Datensätze. Der Makro-F1-Wert berücksichtigt Precision und Recall über alle Klassen hinweg und ist besonders hilfreich, wenn die Klassen nicht vollständig gleich verteilt sind. Cohen's Kappa bewertet zusätzlich, wie stark die Modellleistung über eine zufällige Klassifikation hinausgeht.

Der Decision Tree erreichte auf den Testdaten eine Accuracy von 0,519, einen Makro-F1-Wert von 0,511 und einen Kappa-Wert von 0,240. Der Random Forest erzielte auf den Testdaten bessere Ergebnisse mit einer Accuracy von 0,623, einem Makro-F1-Wert von 0,607 und einem Kappa-Wert von 0,394.

Die 5-fache Cross Validation des Random Forest lag mit einer Accuracy von 0,608, einem Makro-F1-Wert von 0,591 und einem Kappa-Wert von 0,370 nur leicht unter der normalen Testbewertung. Dies deutet auf eine relativ stabile Modellleistung hin.

Im direkten Vergleich schnitt der Random Forest in allen betrachteten Kennzahlen besser ab als der Decision Tree. Deshalb wurde der Random Forest als bestes Modell für dieses Projekt ausgewählt.

Modell	Bewertung	Accuracy	Makro-F1	Kappa
Decision Tree	Testdaten	0,519	0,511	0,240
Random Forest	Testdaten	0,623	0,607	0,394
Random Forest	Cross Validation	0,608	0,591	0,370

Tabelle 2: Modellvergleich anhand zentraler Bewertungskennzahlen




Abbildung 3: Vergleich der Modelleleistung anhand von Accuracy, Makro-F1 und Cohen's Kappa

7. Interpretation der Ergebnisse und Merkmalsbedeutung

Die Ergebnisse zeigen, dass der Random Forest für diese Aufgabenstellung besser geeignet ist als der Decision Tree. Der Decision Tree ist zwar leichter interpretierbar, erreicht aber eine geringere Modelleleistung. Der Random Forest kombiniert mehrere Entscheidungsbäume und kann dadurch komplexere Zusammenhänge im Datensatz besser abbilden.

Die Bewertung zeigt außerdem, dass die Klassifikation der Weinqualität anspruchsvoll ist. Besonders die Abgrenzung zwischen den Klassen medium und high ist schwierig, da sich die chemischen Merkmale dieser Klassen teilweise überschneiden.

Zur besseren Interpretation des Random-Forest-Modells wurde die Merkmalsbedeutung untersucht. Dafür wurden die Attributstatistiken des Random Forest ausgewertet. Betrachtet wurde, wie häufig Merkmale in frühen Baumebenen verwendet wurden.

Die Auswertung zeigte, dass insbesondere Alkoholgehalt, Dichte und flüchtige Säure wichtige Merkmale für die Vorhersage der Qualitätsklassen sind. Der Alkoholgehalt wurde am häufigsten in frühen Baumebenen verwendet. Dieses Ergebnis passt zur explorativen Datenanalyse, in der bereits ein positiver Zusammenhang zwischen Alkoholgehalt und Qualität erkennbar war.

Die Merkmalsbedeutung ist nicht als kausaler Nachweis zu verstehen. Sie zeigt nicht, dass ein Merkmal allein die Qualität verursacht. Sie liefert aber einen nachvollziehbaren Hinweis darauf, welche Merkmale das Modell besonders stark für seine Entscheidungen nutzt.

Merkmal	Anzahl früher Splits
alcohol	127
density	80
volatile acidity	73
citric acid	67
chlorides	64
free sulfur dioxide	56

sulphates	51
total sulfur dioxide	46
residual sugar	43
fixed acidity	31
pH	24
red	21
white	11

Tabelle 3: Merkmalsbedeutung des Random-Forest-Modells




Abbildung 4: Merkmalsbedeutung im Random-Forest-Modell

8. Power-BI-Dashboard

Zusätzlich zur Analyse in KNIME wurde ein Power-BI-Dashboard erstellt. Das Dashboard dient dazu, die wichtigsten Ergebnisse interaktiv und verständlich darzustellen. Während KNIME vor allem für Datenaufbereitung, Modellierung und Bewertung genutzt wurde, ist Power BI besonders geeignet, um Ergebnisse für Anwender übersichtlich zu visualisieren.

Das Dashboard enthält fünf Berichtsseiten: Überblick, Merkmale, Modellvergleich, Merkmalsbedeutung und Fazit. Auf der Überblicksseite werden zentrale Kennzahlen wie Anzahl der Weine, Anzahl Rotwein, Anzahl Weißwein und durchschnittliche Qualität dargestellt. Außerdem werden die Verteilung der Qualitätsklassen und die Verteilung nach Weinart visualisiert.

Die Seite Merkmale zeigt wichtige chemische Merkmale nach Qualitätsklasse, zum Beispiel durchschnittlichen Alkoholgehalt, Dichte und flüchtige Säure. Dadurch werden zentrale Muster aus der explorativen Analyse auch im Dashboard sichtbar.

Die Seite Modellvergleich stellt die Kennzahlen Accuracy, Makro-F1 und Cohen's Kappa dar. Dadurch wird nachvollziehbar, warum der Random Forest als bestes Modell ausgewählt wurde.

Die Seite Merkmalsbedeutung zeigt, welche Eingangsmerkmale im Random-Forest-Modell besonders häufig in frühen Baumebenen verwendet wurden. Die Fazit-Seite fasst die wichtigsten Erkenntnisse, Grenzen und möglichen Weiterentwicklungen zusammen.

Durch Filter nach Weinart und Qualitätsklasse kann der Datensatz interaktiv betrachtet werden. Damit bietet das Dashboard einen praktischen Nutzen für die schnelle Analyse und Kommunikation der Projektergebnisse.

Dashboard-Seite	Inhalt	Nutzen
Überblick	KPI-Karten, Qualitätsklassen, Weinarten, Filter	schneller Einstieg in Datenstruktur und Verteilungen
Merkmale	Alkohol, Dichte, flüchtige Säure nach Qualitätsklasse	chemische Unterschiede zwischen Qualitätsklassen sichtbar machen
Modellvergleich	Accuracy, Makro-F1, Kappa	Modellauswahl nachvollziehbar darstellen
Merkmalsbedeutung	Rangliste der wichtigsten Merkmale	Einflussmerkmale des Random Forest interpretieren
Fazit	zentrale Erkenntnisse, Grenzen, Ausblick	Ergebnisse kurz und verständlich zusammenfassen

Tabelle 4: Aufbau und Nutzen des Power-BI-Dashboards

9. Grenzen des Modells

Obwohl der Random Forest im Vergleich zum Decision Tree bessere Ergebnisse erzielt, ist die Modellleistung insgesamt nur mittelstark. Eine Accuracy von etwa 0,62 zeigt, dass das Modell einen Teil der Qualitätsklassen korrekt erkennt, aber weiterhin Fehlklassifikationen auftreten.

Ein Grund dafür ist, dass die Qualitätsklassen auf Basis einer ursprünglichen numerischen Bewertung gebildet wurden. Die Grenzen zwischen low, medium und high sind dadurch vereinfacht festgelegt. Besonders Weine im Übergangsbereich zwischen zwei Klassen können schwer eindeutig zugeordnet werden.

Außerdem überschneiden sich die chemischen Merkmale der Qualitätsklassen teilweise stark. Ein Wein mit mittlerer Qualität kann ähnliche Werte besitzen wie ein Wein mit hoher Qualität. Dadurch ist besonders die Unterscheidung zwischen medium und high schwierig.

Eine weitere Grenze besteht darin, dass der Datensatz nur chemische Messwerte enthält. Sensorische Faktoren wie Geruch, Geschmack, Mundgefühl oder Gesamteindruck wurden nicht berücksichtigt. Auch Informationen wie Herkunft, Rebsorte, Lagerung oder Herstellungsverfahren fehlen.

Die Ergebnisse dürfen daher nicht als endgültige Qualitätsentscheidung verstanden werden. Das Modell eignet sich vor allem als datenbasierter Prototyp zur Unterstützung der Analyse.

10. Fazit und Ausblick

Im Projekt wurde ein vollständiger Datenanalyseprozess zur Klassifikation der Weinqualität umgesetzt. Die Rot- und Weißweindaten wurden importiert, zusammengeführt, geprüft, bereinigt und für die Modellierung vorbereitet. Anschließend wurden explorative Analysen durchgeführt, um wichtige Muster und Zusammenhänge im Datensatz zu erkennen.

Für die Vorhersage der Qualitätsklassen wurden zwei Modelle trainiert und bewertet: ein Decision Tree und ein Random Forest. Der Decision Tree diente als einfaches und gut interpretierbares Vergleichsmodell. Der Random Forest erzielte in den verwendeten Bewertungskennzahlen bessere Ergebnisse und wurde deshalb als bestes Modell ausgewählt.

Die zusätzliche Cross Validation zeigte, dass die Leistung des Random-Forest-Modells relativ stabil ist. Trotzdem ist die Modellleistung insgesamt nur mittelstark. Besonders die Abgrenzung zwischen den Klassen medium und high bleibt schwierig, da sich die chemischen Merkmale teilweise überschneiden.

Die Analyse der Merkmalsbedeutung zeigte, dass insbesondere Alkoholgehalt, Dichte und flüchtige Säure wichtige Rollen bei der Klassifikation spielen. Diese Ergebnisse passen zu den Erkenntnissen aus der explorativen Datenanalyse und machen die Modellentscheidung besser nachvollziehbar.

Für eine Weiterentwicklung könnten zusätzliche Merkmale einbezogen werden, zum Beispiel Herkunft, Rebsorte, Lagerung oder sensorische Bewertungen. Außerdem könnten weitere Machine-Learning-Modelle getestet und die Klassengrenzen fachlich genauer überprüft werden. Das Power-BI-Dashboard kann als Grundlage dienen, um die Projektergebnisse übersichtlich zu präsentieren und mit Anwendern zu diskutieren.

Ende des Projektberichts